




Samir Belasri

Academy

**Analyse Exploratoire de Données
Éducatives Mondiales**

Roadmap



Introduction – Pourquoi ces données sont importantes ?

- Comprendre l'Éducation Mondiale : Un Aperçu des Données
- Points Clés :
 - Ces données proviennent de statistiques éducatives mondiales (Banque Mondiale / UNESCO).
 - Lien Métier : Pourquoi est-ce important pour une organisation/entreprise ? Pour comprendre les niveaux d'éducation dans différents pays, identifier les marchés potentiels, adapter les stratégies de formation, ou évaluer l'impact de projets éducatifs.



Ma Démarche d'Analyse

- Ce que j'ai fait : J'ai suivi un processus en plusieurs étapes :
 - a.Chargement et Nettoyage des données (suppression des données inutiles, identification des vrais pays).
 - b.Sélection et Préparation des indicateurs clés.
 - c.Analyse approfondie et Sélection des pays cibles.
- Mon objectif : Transformer les données disponibles en informations exploitables pour notre décision stratégique.

Nettoyage des Données : Une Étape Cruciale

- Ce que j'ai fait : J'ai géré les valeurs manquantes (certaines colonnes étaient presque vides) et j'ai filtré les "faux pays" (regroupements d'États) pour me concentrer uniquement sur les pays individuels.
- Mon observation : Le nettoyage a permis de rendre les données fiables pour l'analyse.



Sélection de Mes Indicateurs Clés

- Ce que j'ai fait : J'ai exploré plus de 3500 indicateurs et j'ai sélectionné environ 15 indicateurs clés basés sur leur pertinence pour l'étude et surtout sur la quantité de données disponibles pour les années 2005 et 2010.
- Ma décision : Pour simplifier et réduire la redondance (les données 2005 et 2010 étaient très corrélées), j'ai décidé de me concentrer sur les données de l'année 2010 pour ces indicateurs.

Mes Indicateurs Clés (Suite)

- Ce que j'ai analysé : Mes indicateurs couvrent des domaines essentiels :
 - Démographie (Population totale, structure par âge)
 - Économie (PIB, Population active)
 - Éducation (Taux d'alphabétisation, Taux de scolarisation, Taux d'achèvement à différents niveaux, Dépenses d'éducation).



Comprendre la Distribution des Indicateurs

- Analyse : Comment les pays se situent-ils ?
- Ce que j'ai fait : J'ai analysé la répartition des valeurs pour chaque indicateur parmi les pays (statistiques descriptives, graphiques).
- Mon observation : Pour certains indicateurs (Population, PIB), quelques pays ont des valeurs très élevées, tandis que la majorité ont des valeurs plus faibles. Cela montre de grandes disparités.

Mes Pays Recommandés pour l'Expansion

- Mes Pays Cibles Potentiels (Top 15)
- Mon action : J'ai classé les pays selon la somme de leurs rangs (du plus faible au plus élevé) et j'ai sélectionné les 15 pays les mieux classés, en m'assurant qu'ils avaient suffisamment de données pour un classement fiable.



Récapitulatif de ma Démarche

J'ai structuré mon travail en plusieurs phases, couvrant les trois exercices :

Exercice 1 : Découverte et Nettoyage des Données

J'ai chargé et exploré les cinq fichiers de données CSV.
J'ai identifié les DataFrames clés (EdStatsCountry, EdStatsSeries, EdStatsData).
J'ai nettoyé le DataFrame principal (EdStatsData) en supprimant les colonnes avec trop de valeurs manquantes.
J'ai filtré les DataFrames pour ne conserver que les données correspondant aux pays réels, en excluant les agrégats.
J'ai présenté une première Conclusion Intermédiaire sur l'état des données après nettoyage.

Exercice 2 : Analyse des données de systèmes éducatifs

J'ai exploré le DataFrame EdStatsSeries pour comprendre les indicateurs disponibles.
J'ai fait une sélection préliminaire d'indicateurs pertinents.
J'ai filtré mon tableau de données nettoyé pour ne garder que les données liées à mes indicateurs préliminaires et aux années 2005 et 2010.
J'ai évalué la complétude des données pour ces indicateurs sur ces années en calculant le pourcentage de données disponibles.
J'ai fait une sélection finale d'environ 15 indicateurs basés sur leur richesse en données.
J'ai transformé mon tableau de données en utilisant melt() et pivot_table() pour organiser les données avec les pays en lignes et les indicateurs/années en colonnes.
J'ai vérifié la qualité du tableau transformé et documenté le processus.
J'ai présenté une deuxième Conclusion Intermédiaire sur la sélection et la transformation des données.

Exercice 3 : Analyse approfondie et Sélection des Pays

J'ai préparé mon tableau transformé pour l'analyse de corrélation en isolant les colonnes numériques.
J'ai calculé et visualisé les matrices de corrélation (Pearson et Spearman) entre les indicateurs.
J'ai identifié les indicateurs fortement corrélés et j'ai pris la décision de supprimer les colonnes de 2005 pour réduire la redondance, en conservant uniquement les données de 2010 pour les indicateurs finaux.
J'ai documenté les indicateurs finaux retenus pour l'analyse.
J'ai analysé la distribution de chaque indicateur final pour comprendre la répartition des valeurs parmi les pays.
J'ai défini une méthode quantitative basée sur le classement des pays pour chaque indicateur afin de les évaluer globalement.
J'ai appliqué cette méthode pour construire la liste finale des pays pertinents pour l'expansion.



Liste des codes et noms des indicateurs finaux pour 2010

Après mon analyse de corrélation et la réduction de la redondance, j'ai choisi de me concentrer sur les indicateurs suivants, en utilisant leurs données pour l'année 2010 :

- Liste des codes et noms des indicateurs finaux pour 2010 :
 - SP.POP.TOTL_2010 – Population, total
 - NY.GDP.MKTP.CD_2010 – GDP (current US\$)
 - SP.POP.0014.TO.ZS_2010 – Population ages 0–14 (% of total)
 - SP.POP.1564.TO.ZS_2010 – Population ages 15–64 (% of total)
 - SL.TLF.TOTL.IN_2010 – Total labor force
 - BAR.NOED.15UP.ZS_2010 – Barro–Lee: Percentage of population age 15+ with no education
 - SE.ADT.LITR.ZS_2010 – Adult literacy rate, population 15+ years
 - SE.PRM.CMPT.ZS_2010 – Primary completion rate, both sexes
 - SE.SEC.CMPT.LO.ZS_2010 – Lower secondary completion rate, both sexes
 - SE.SEC.CMPT.UP.ZS_2010 – Upper secondary completion rate, both sexes
 - SE.TER.ENRR_2010 – Gross enrolment ratio, tertiary, both sexes
 - SE.XPD.TOTL.GD.ZS_2010 – Government expenditure on education as % of GDP
 - UIS.NERA.1_2010 – Adjusted net enrolment rate, primary
 - UIS.NERA.2_2010 – Adjusted net enrolment rate, lower secondary
 - UIS.NERA.3_2010 – Adjusted net enrolment rate, upper secondary



Ma Méthode de Sélection des Pays

Pour identifier les pays potentiels pour l'expansion, j'ai mis en place une méthode quantitative basée sur le classement des pays pour chaque indicateur clé (données 2010) :

- Classement par indicateur : J'ai classé tous les pays pour chaque indicateur, en donnant le rang 1 au pays ayant la valeur la plus favorable (la plus élevée ou la plus faible, selon l'indicateur).
- Somme des rangs : J'ai calculé la somme de tous les rangs obtenus par chaque pays sur l'ensemble des indicateurs.
- Sélection finale : J'ai identifié les pays qui avaient la somme totale des rangs la plus faible (les mieux classés globalement). J'ai aussi pris en compte le nombre d'indicateurs pour lesquels un pays avait des données pour assurer la fiabilité du classement. J'ai sélectionné les 15 pays arrivant en tête de ce classement final.



Pays Recommandés pour l'Expansion

Basé sur mon analyse approfondie et ma méthode de classement quantitative, voici la liste des pays que j'identifie comme les plus pertinents pour une potentielle expansion, en tenant compte des indicateurs éducatifs et socio-économiques analysés pour l'année 2010 :

- Liste des codes et noms des pays sélectionnés :

- KOR – Korea, Rep.
- FIN – Finland
- NOR – Norway
- CHE – Switzerland
- DNK – Denmark
- NLD – Netherlands
- SWE – Sweden
- AUS – Australia
- ISL – Iceland
- BEL – Belgium
- IRL – Ireland
- AUT – Austria
- NZL – New Zealand
- CAN – Canada



Interprétation et Préconisation

Les pays que j'ai identifiés se classent favorablement sur l'ensemble des indicateurs clés que j'ai analysés (taille de la population et de l'économie, structure démographique, niveaux d'éducation, investissements dans l'éducation). Cela suggère qu'ils présentent des caractéristiques potentiellement propices à une expansion, en termes de marché, de capital humain et d'environnement éducatif.

Ma préconisation est que cette liste de pays constitue une excellente base de départ pour une exploration plus approfondie. Il serait pertinent de compléter cette analyse quantitative par :

- Des analyses qualitatives sur ces pays (environnement politique et réglementaire, spécificités culturelles, concurrence locale, etc.).
- L'analyse d'indicateurs supplémentaires s'ils sont disponibles et jugés pertinents par les experts métier.
- L'utilisation de données plus récentes si possible.

Cependant, sur la base des données disponibles pour 2010 et de la méthode quantitative que j'ai appliquée, ces pays sont ceux qui se démarquent le plus. Mon dossier présente une méthode transparente et reproductible pour arriver à cette première sélection de pays cibles.



Heatmap de la matrice de corrélation de Pearson (représentative des relations entre indicateurs) :




Tableau des 15 pays les mieux classés (résultat final) :

Country Code	Short Name	Table Name	Long Name	2-alpha code	Currency Unit	Special Notes	Region	Income Group	WB-2 code	National accounts base year	...	IMF data dissemination standard	Latest population census	Latest household survey	Source of most recent Income and expenditure data	V registration comp
JPN	Japan	Japan	Japan	JP	Japanese yen	Fiscal year end: March 31; reporting period fo...	East Asia & Pacific	High income: OECD	JP	2005	...	Special Data Dissemination Standard (SDDS)	2010	NaN	Income survey (IS), 1993	
FRA	France	France	French Republic	FR	Euro	A simple multiplier is used to convert the nat...	Europe & Central Asia	High income: OECD	FR	Original chained constant price data are resca...	...	Special Data Dissemination Standard (SDDS)	2006. Rolling census based on continuous sampl...	NaN	Expenditure survey/budget survey (ES/BS), 1994/95	
ITA	Italy	Italy	Italian Republic	IT	Euro	A simple multiplier is used to convert the nat...	Europe & Central Asia	High income: OECD	IT	2005	...	Special Data Dissemination Standard (SDDS)	2012	NaN	Expenditure survey/budget survey (ES/BS), 2000	

Samir Belasri



Thank You