



Concevez et déployez un système RAG


Soutenance de Projet Data Engineering —
De la donnée brute à l'assistant conversationnel




Python



Mistral AI



FAISS




LangChain

Samir Belasri



Contexte & Objectif du Projet

Le Contexte



- **Le Contexte** : Accès complexe aux vastes bases de données d'événements (OpenAgenda).
- **Le Problème** : La recherche classique par mots-clés est rigide et ignore l'intention réelle de l'utilisateur.

L'Objectif (POC)

A diagram of a speech bubble with a dark blue border and a light blue fill. The text 'Je cherche **une sortie culturelle** pour ce **week-end** dans la région.' is inside. A large orange arrow points from the 'Le Contexte' section towards the speech bubble. A small orange circle is located at the bottom-left corner of the speech bubble, with a line connecting it to the second bullet point in the 'L'Objectif (POC)' section.

Je cherche **une sortie culturelle** pour ce **week-end** dans la région.

- **L'Objectif (POC)** : Concevoir un **assistant** de bout en bout capable de **recommander** des **événements** via le **langage naturel**.

Moteur Lexical vs Compréhension Sémantique

Recherche Lexicale (Classique)

 Mécanisme : Basée uniquement sur l'occurrence exacte des termes (ex: SQL, Elasticsearch basique).

 Le mur de la synonymie : Une requête « Intelligence Artificielle » ne trouve pas un événement taggué « Machine Learning ».

Compréhension Sémantique (La Cible)


Mécanisme : Transformation des textes en vecteurs pour capturer la proximité des concepts.

Recherche de sens : Passer d'une simple recherche de termes précis à une véritable compréhension de l'intention globale.

Le paradigme RAG (Retrieval-Augmented Generation)


Le Principe : Coupler la fluidité linguistique d'un LLM avec une base de connaissances externe et factuelle.

Efficience technique : Zéro réentraînement (fine-tuning) requis, réduisant drastiquement les coûts de calcul.



Sécurité des données : Lutte active contre les hallucinations en forçant le LLM à s'appuyer sur le contexte injecté.

Vue globale du Pipeline de Traitement



Une architecture modulaire où chaque composant est testable et isolable.


Outils et Choix Architecturaux



FAISS

Vector Store léger

Choisi pour sa performance en local sans nécessiter le déploiement d'une infrastructure lourde ou coûteuse.



Mistral AI

LLM & Embeddings

Choisi pour son excellent ratio performance/coût et sa grande pertinence dans le traitement de la langue française.



LangChain

Orchestrateur

Framework devenu un standard industriel pour la gestion fluide des prompts et le chaînage complexe du pipeline RAG.




Pandas & Pytest


Data Eng & Fiabilité

Nettoyage standardisé des données JSON et tests unitaires continus pour garantir la solidité et la reproductibilité du pipeline.

Pipeline Data : De la source au socle



Sous le capot : Le flux d'inférence RAG



Démonstration : De la requête au résultat

Requête Utilisateur : « Je cherche une conférence scientifique. »

Contexte récupéré - FAISS


```
{  
  "titre": "Les mystères de l'infiniment petit",  
  "lieu": "Campus Universitaire, Gif-sur-Yvette",  
  "date": "12 Novembre",  
  "type": "Conférence scientifique"  
}
```

Réponse générée - Mistral AI


Je vous recommande la conférence « Les mystères de l'infiniment petit » qui se tiendra sur le Campus Universitaire de Gif-sur-Yvette le 12 Novembre. Cet événement scientifique vous permettra de découvrir...

Analyse : Le système interprète le terme « scientifique », filtre spatialement les résultats pertinents (Gif-sur-Yvette), et structure une réponse humainement lisible à partir de JSON brut.


Analyse critique du POC



Vers l'industrialisation



Bilan et Création de Valeur



Faisabilité technique prouvée

Le pipeline complet, de l'ingestion API à la recommandation conversationnelle, est totalement opérationnel et évalué.

Création de valeur métier

Transition réussie d'une base de données rigide vers un véritable assistant interactif et contextualisé, répondant aux attentes utilisateurs.

Fondation logicielle solide

Un socle d'ingénierie modulaire, documenté et testé via Pytest, immédiatement prêt à être itéré vers une version de production.